

base 와 instruct, 무엇이 다른가

측정으로 확인된 차이만 정리 . 근본 원인은 하나 — **instruction-tuning 유무** . 속도 · 메모리 · 연산량은 동일합니다 .

측정 항목	base	instruct	원인 (간단)
SWE-bench 패치 생성	0 개	40 개 (포맷 invalid)	instruct 만 ‘패치를 만들라’는 지시를 수행
chat 프롬프트 출력	0 토큰 · 즉시 종료	정상 생성 (gen 33.7s)	base 는 chat/ 지시 포맷 미학습 → 입력 받자마자 EOS
합성 프롬프트 출력	512 토큰 (안 멈춤)	~104 토큰 (EOS)	instruct 만 ‘적절히 멈추기 (EOS)’ 를 학습
집계 throughput (동시성 256)	~1,800 tok/s	~1,410 tok/s	디코드 속도차 아님 — 짧은 출력이 배치를 일찍 비워 점유율↓

동일 (차이 없음) 모델 크기 bf16 ≈28 GB · tp8 1 장 (npu:0) · 단일스트림 토큰당 지연 ITL 0.0325 s · SWE-bench 해결률 0/50 · 연산 그래프 (바이너리 크기 동일 , md5 만 상이)