

RNGD 모델 벤치마크 — 핵심 결과

단일 스트림 디코드 속도와 동시성 **peak 합산 처리량** 요약 · peak 합산 TPS@c = 가장 높은 총처리량과 그때의 동시 요청 수 · 실패 0 기준

모델	카드	TTFT p50(s)	단일 TPS	peak 합산 TPS @ 동시성	효율 배치
Qwen2.5-0.5B Instruct	1 장	0.031	84.5	4,120 @c128	c128
Qwen2.5-Coder-1.5B ★ 종합 1 위	1 장	0.020	95.5	3,443 @c256	c256
Qwen2.5-Coder-7B Instruct	1 장	0.032	50.3	2,225 @c256	c256
Llama-3.1-8B Instruct	1 장	0.033	54.5	2,192 @c128	c128
Qwen2.5-Coder-14B Instruct	1 장	0.050	30.7	1,074 @c256	c128
EXAONE-4.0-32B FP8	4 장	0.221	30.4	809 @c256	c256
Llama-3.3-70B Instruct	4 장	0.247	24.5	383 @c128	c128
Qwen3-32B FP8	4 장	—	—	25 @c1	c1
Qwen3-32B FP8	1 장	—	—	5 @c1	c1

핵심 종합 1 위 Qwen2.5-Coder-1.5B(1 장) — 동시성 256 까지 무손실 3,443 tok/s. Qwen3-32B FP8(흐림) 은 동시성↑ 시 실패 급증 → 1~4 장 모두 c1 만 안정

빌드한 artifact 목록

로컬 빌드 7 개 + **prebuilt(HF)** 3 개 = 총 10 개 · 약 426 GB · 정밀도는 params 파일명 (W8f=FP8 / W16=bf16) 으로 확정

아티팩트 (디렉토리)	모델 · 정밀도 · 컨텍스트	TP · 카드	크기	빌드 유형
qwen2.5-coder-7b-inst-tp8	Qwen2.5-Coder-7B Instruct · bf16	tp8 · 1 장	15 GB	로컬빌드
qwen2.5-coder-14b-inst-tp8	Qwen2.5-Coder-14B Instruct · bf16	tp8 · 1 장	28 GB	로컬빌드
qwen2.5-coder-14b-tp8	Qwen2.5-Coder-14B base · bf16	tp8 · 1 장	28 GB	로컬빌드
qwen3-32b-fp8-tp8	Qwen3-32B · FP8	tp8 · 1 장	33 GB	로컬빌드
qwen3-32b-fp8-tp8-16k	Qwen3-32B · FP8 · 16k ctx	tp8 · 1 장	33 GB	로컬빌드
qwen3-coder-30b-a3b-inst-fp8-tp8-65k-tc	Qwen3-Coder-30B-A3B Inst · FP8 · 65k	tp8 · 1 장	30 GB	로컬빌드
qwen3-coder-30b-a3b-inst-tp8-65k-tc	Qwen3-Coder-30B-A3B Inst · bf16 · 65k	tp8 · 1 장	58 GB	로컬빌드
exaone-4.0-32b-fp8-tp32	EXAONE-4.0-32B · FP8	tp32 · 4 장	34 GB	prebuilt
qwen3-32b-fp8-tp32	Qwen3-32B · FP8	tp32 · 4 장	34 GB	prebuilt
llama-3.3-70b-inst-tp32	Llama-3.3-70B Instruct · bf16	tp32 · 4 장	133 GB	prebuilt

미완 2 개 (제외) qwen3-coder-30b-a3b-inst-fp8-tp8-65k (18 MB) · qwen3-coder-30b-a3b-inst-tp8-65k (16 MB) — artifact.json 만 있고 빌드 산출물 0 → 위 -tc 변형이 완성본