

furiosa-llm build 한 줄이 하는 일 — 7 단계

명령 한 줄을 넣으면 1.1 → 1.7 순서로 진행돼, 마지막엔 ./out/ 에 NPU 가 그대로 실행할 모델 꾸러미 (아티팩트) 가 생깁니다.

```
$ furiosa-llm build Qwen/Qwen3-Coder-30B-A3B-Instruct-FP8 ./out -tp 8 --max-model-len 65536
```

단계	하는 일 — 쉽게 풀어서	한 줄 비유
1.1 명령 접수	내가 친 옵션 (-tp 8, --max-model-len 등) 을 프로그램이 알아듣는 설정 6 묶음으로 옮겨 적습니다.	주문을 정식 양식으로 옮겨 적는 웨이터
1.2 검증	설정이 규칙에 맞나 빠르게 검증 합니다 (tp 는 4·8·32 만, 모델 정보 필수 항목 있나). 틀리면 몇 시간 빌드 전에 즉시 거부 .	공연장 입구의 검표 — 표 틀리면 바로 돌려보냄
1.3 기본값 채우기	안 준 값을 자동 결정: 모델 신원 (qwen3_moe·FP8), 컨텍스트 길이, NPU 배치, 그리고 버킷 (미리 구울 고정 길이 목록).	신원조회 + 옷 치수표 정하기
1.4 가중치 적재 + 양자화	모델의 숫자 (가중치) 를 불러와 FP8 로 압축 해 용량을 줄입니다. 결과 파일 이름이 곧 명세서 (48L·W8fA16KV16).	256 색 그림을 16 색으로 인쇄 — 중요한 글자만 풀컬러
1.5 트레이싱 (설계도 뽑기)	모델을 한 번 따라 돌려 계산 순서를 그래프 (설계도) 로 기록합니다. 버킷 (길이) 마다 한 장씩, Ray 일꾼이 수행.	악보 (계산그래프) 와 가사집 (가중치) 을 따로 인쇄

어려운 말 풀이

양자화 (FP8) 가중치 숫자를 적은 비트로 줄여 용량·속도↑ (W8fA16KV16= 가중치 FP8, 활성·KV 는 BF16) · **버킷** NPU 가 미리 컴파일해 두는 고정 입력 길이 (128·256·1024 …). NPU 는 동적 크기에 약해 치수별로 따로 굽습니다.

트레이싱 모델을 한 번 실행해 계산 순서를 그래프로 기록 · **EDF** NPU 가 직접 읽는 실행 포맷 (기계어 + 배선도) · **supertask/stage** 컴파일 단위. 레이어 1 개 = [앞 tokenwise | attention | 뒤 tokenwise] 3 조각으로

출처: info/ALL_about_build_server.md Part 1 (1.1~1.7) · **일** build_trace_furilog · **코드** cli/convert.py · builder.py · validator.py · resolver.py · trace.py · converter.py

저장 / 패키징 번역 결과 (EDF) 를 **binary bundle.zip** 으로 묶고 **artifact.json·가중치·토큰나이저**를 ./out/ 한 폴더에 저장 · **약기 파트보 (EDF) 를 한 폴더로 압축·납품**