

모델 프레임워크 — RNGD 가 실행하는 모델 ↔ furiosa.models 클래스

Furiosa SW 스택의 최상단 .furiosa-llm 은 HF config 의 architectures 이름과 똑같은 이름의 클래스를 furiosa.models 에서 찾아 (getattr) NPU 용으로 실행합니다 .

연결 규칙

model.config.architectures[0] (예 : "LlamaForCausalLM") → getattr(furiosa.models, name) → CausalModelServer → NPU 실행

furiosa.models 클래스	model_type	종류	RNGD 에서 쓰는 모델 (예시)
★ LlamaForCausalLM	llama	Dense	Llama 3.1 8B·70B, 3.3 70B, DeepSeek-R1-Distill-Llama, CodeLlama
★ Qwen2ForCausalLM	qwen2	Dense	Qwen2.5 0.5~32B, Qwen2.5-Coder 1.5~32B, DeepSeek-R1-Distill-Qwen, QwQ-32B
★ Qwen3ForCausalLM	qwen3	Dense	Qwen3 4B·8B·32B(FP8), Qwen3-Embedding·Reranker
★ Exaone4ForCausalLM	exaone4	Dense	EXAONE-4.0-32B
ExaoneForCausalLM	exaone	Dense	EXAONE 3.0·3.5·Deep
MistralForCausalLM	mistral	Dense	Mistral 계열 (preset 없음 → 버킷 수동)
Phi3ForCausalLM	phi3	Dense	Phi-3 계열 (preset 없음 → 버킷 수동)
★ Qwen3MoeForCausalLM	qwen3_moe	MoE	Qwen3-30B-A3B-Instruct, Qwen3-Coder-30B-A3B
★ GptOssForCausalLM	gpt_oss	MoE	gpt-oss 20B·120B
ExaoneMoeForCausalLM	exaone_moe	MoE	EXAONE MoE 계열
Qwen3VLForConditionalGeneration	qwen3_vl	VL	Qwen3-VL (이미지 + 텍스트 멀티모달)

★ = furiosa-llm 공식 지원 집합 (CANONICAL_MODEL_IDS) · Dense 전 파라미터 사용 MoE 전문가 일부만 활성 VL 비전 - 언어 · 임베딩 · 리랭킹은 Qwen3 를 pooling/score 태스크로 사용

출처 : furiosa_llm/optimum/modeling.py:138(CANONICAL_MODEL_IDS)::173(get_models_lang_class)::431 (AutoModelForCausalLM) · furiosa.models.language.architecture.* · `import furiosa.models` 로 클래스 11 종 실재 확인 (furiosa-llm 2026.2.0)