

텐서를 쪼개나 (TP) · 레이어를 쪼개나 (PP) · 모델을 복제하나 (DP)

같은 4 장 (32 PE) 이라도 '무엇을' 나누느냐가 다릅니다 . TP 는 한 연산을 , PP 는 레이어를 , DP 는 요청을 나눕니다 .

TP · 텐서 병렬 (Tensor Parallel)

한 레이어의 가중치 행렬 W

W0

W1

W2

W3

NPU 1 장 (8 PE)

PE0

PE1

PE2

PE3

행렬을 PE 수만큼 쪼개 동시 계산
(예 : tp8 → 8 조각) . 한 요청을 여러 PE 가 분담 → 가속

- 빌드 때 고정 (바이너리에 박힘 → serve 가 못 바꿈)
- 단일 요청 가속 O (한 연산을 PE 가 분담)
- RNGD 1 장 = 8 PE · tp≤8 = 1 장

PP · 파이프라인 병렬 (Pipeline Parallel)

입력 토큰

카드 0 — Stage 0
Layer 0~23

카드 1 — Stage 1
Layer 24~47

출력

레이어를 스테이지로 나눠 카드별 배치 .
토큰이 카드→카드 순차 통과 (1 장 초과 모델 적재용)

- 빌드 + serve 둘 다 (serve = 블록 재그룹)
- 1 장 초과 모델 적재 · KV 풀 확장
- ⚠ 단일 요청 가속 아님 (파이프라인 버블)

DP · 데이터 병렬 (Data Parallel)

라우터 (요청 분배 · round-robin)

복제본 0
전체 모델 (npu:0)

복제본 1
전체 모델 (npu:1)

같은 아티팩트를 통째로 복제 .
요청을 나눠 처리 → 동시 처리량 ≈ N 배

- serve 런타임만 (재컴파일 불필요)
- 동시 요청 처리량 ↑ (복제 수만큼)
- 아티팩트엔 안 박힘 → 가용 PE 로 자동 결정

예) RNGD 4 장 (32 PE): tp8(1 장 분할) × dp4(4 장 복제) = 32 PE 전부 사용 · dp × pp ≤ 카드 수 · tp 는 빌드 때 , pp·dp 는 serve 때 조정