

# furiosa-llm serve 옵션 한눈에

엔진을 띄우는 유일한 CLI. 위치인자 model(HF id 또는 아티팩트 경로) + 옵션들. 기본값은 (기본 ...) 으로 표기.

```
$ furiosa-llm serve <model> [--port 8000] [-tp 8] [-dp 4] [--enable-prefix-caching] ...
```

| 기본 / 접속                        |                                                             |
|--------------------------------|-------------------------------------------------------------|
| model (위치인자)                   | HF 모델 id 또는 Furiosa 아티팩트 경로 · 서버당 1 개                       |
| --revision                     | HF 리버전 (브랜치 / 태그 / 커밋). 기본 main · furiosa-ai 모델은 release 태그 |
| --served-model-name            | API 에 노출할 모델 이름 (기본 : model 인자)                             |
| --host                         | 바인드 호스트 (기본 0.0.0.0)                                        |
| --port                         | 바인드 포트 (기본 8000)                                            |
| 병렬화 / 디바이스                     |                                                             |
| -tp, --tensor-parallel-size    | 텐서 병렬 수 (기본 4)                                              |
| -pp, --pipeline-parallel-size  | 파이프라인 스테이지 수                                                |
| -dp, --data-parallel-size      | 데이터 병렬 수 (미지정 시 가용 PE 로 추론)                                 |
| --devices                      | 사용 디바이스. npu:0 / npu:0:0 / npu:0:0-3                        |
| --data-parallel-routing-policy | dp 라우팅 : round_robin / prefix_aware                         |
| 버킷 / 길이 / 배치                   |                                                             |
| -pb, --prefill-buckets         | prefill 버킷 (기본 : 아티팩트 값)                                    |
| -db, --decode-buckets          | decode 버킷 (기본 : 아티팩트 값)                                     |
| --max-prompt-len               | 캡처할 최대 프롬프트 길이 (초과 버킷 무시)                                   |
| --max-model-len                | 최대 자원 시퀀스 길이 (초과 버킷 무시)                                     |
| --max/min-batch-size           | npu 요청당 최대 / 최소 배치 (벗어난 버킷 무시)                              |
| 채팅 / 톨 / 추론 파서                 |                                                             |
| --chat-template                | 채팅 템플릿 파일로 덮어쓰기 (기본 : tokenizer)                            |
| --chat-template-content-format | auto / string / openai (기본 auto)                            |
| --enable-auto-tool-choice      | 톨 자동 선택 (--tool-call-parser 필요)                             |
| --tool-call-parser             | hermes / llama4_json / llama3_json / openai                 |
| --reasoning-parser             | deepseek_r1 / exaone4 / qwen3 (추론 모델용)                      |
| --response-role                | chat 응답 role (기본 assistant)                                 |
| --structured-outputs-backend   | 구조화 출력 엔진 : auto / guidance / xgrammar                      |

| 스케줄러 / 성능                                   |                                           |
|---------------------------------------------|-------------------------------------------|
| --scheduler-kind                            | 특화 전략 스케줄러 선택 (기본 : 범용)                   |
| --npu-queue-limit                           | NPU 큐 한도 override (기본 : 아티팩트)             |
| --max-processing-samples                    | 최대 처리 샘플 override                         |
| --spare-blocks-ratio                        | 여유 블록 비율 (기본 0.0 · ↑ 시 성능↑ / OOM 위험)      |
| --estimation-time-limit-ms                  | 배칭 전략 추정 시간 한도 (ms)                       |
| --enable-prefix-caching                     | prefix 캐시 켜기 / 끄기                         |
| --max-concurrency                           | iter 당 최대 동시 decode (↑ throughput, TTFT↑) |
| --max-num-batched-tokens                    | iter 당 최대 배치 토큰 (↑ TPOT, TTFT↑)           |
| --prefix-cache-lookahead-requests           | prefix 캐시 lookahead 요청 수 (실험)             |
| --max-io-memory-mb                          | I/O 텐서용 NPU 메모리 MB (0-49152). 작으면 OOM     |
| 인증 / 로깅 / 보안                                |                                           |
| --api-key                                   | Bearer 토큰 인증 키 (기본 None = 인증 끄)           |
| --allowed-origins                           | 허용 origin (json list, 기본 ["*"])           |
| --disable-log-stats                         | 통계 로깅 끄기                                  |
| --enable-payload-logging                    | POST 페이로드 로깅 (민감정보 노출 위험)                 |
| 멀티모달 / Responses API                        |                                           |
| --allowed-local-media-path                  | 로컬 미디어 접근 경로 (미설정 시 차단)                   |
| --allowed-media-domains                     | 원격 미디어 허용 도메인 (SSRF 방어)                   |
| --image/video-limit-per-prompt              | 프롬프트당 이미지 / 비디오 개수 제한                     |
| --interleave-mm-strings                     | 멀티모달 placeholder 원위치 삽입                   |
| --enable-responses-api-store                | Responses API 인메모리 저장 (멀티턴)               |
| --responses-api-store-*                     | 저장 max-entries(기본 10000) · ttl(기본 3600s)  |
| uvicorn · JIT( 실험 ) · v3                    |                                           |
| --uvicorn-log-level                         | debug~critical / trace (기본 info)          |
| --disable-uvicorn-access-log                | uvicorn 접근 로그 끄기                          |
| --enable-jit-compilation                    | JIT 컴파일 켜기 (실험)                           |
| --jit-threshold / -max-workers / -unit-size | 트리거 5 / 워커 15 / 유닛 8                      |
| --fxb                                       | FXB 파일 · 디렉터리 경로 → v3 엔진 사용               |