

RNGD vs RTX PRO 6000

블로그 효율 벤치마크 직접 재현

Furiosa 블로그의 Qwen3-32B 비교를 내 장비 RNGD 1 장 vs RTX PRO 6000 1 대로 같은 조건 측정

핵심 결론

raw 속도는 GPU, 효율은 RNGD — 같은 일을 1/3 전력으로

단일 카드 raw 처리량은 PRO 6000 이 최대 2.6 배 빠르지만 (984 vs 377 tok/s), RNGD 는 전력이 1/3($\approx 180\text{W}$ vs $\approx 500\text{W}$) 이라 와트당 처리량 (tokens/s/W) 이 저 ~ 중부하에서 최대 2.03 배 . 블로그의 1.8~2x 사용자 우위는 4 장 + 랙 전력 정규화에서 나오는 값 .

측정 모델

Qwen3-32B FP8

RNGD weight-FP8 · GPU 공식 W8A8

워크로드

ISL 1024 / OSL 256

배치 (= 동시 사용자) 1~256 스왑

비교 장비

1 장 vs 1 대

RNGD tp8 1 카드 · RTX PRO 6000 1 대

블로그는 무엇을 주장했나 — 그리고 우리가 검증한 것

블로그의 1.8~2x 는 본문에 "normalized for rack power"(랙 전력 정규화 후) 로 명시됨

블로그 핵심 주장 (4x RNGD 서버 기준)

RNGD 가 RTX PRO 6000 보다 1.8x · 1.9x · 2.0x 더 많은 사용자 (SLO 20·30·40 TPS/user, 랙 전력 정규화) · 전력 8 장 3kW vs 6.6kW · 랙당 2.5x

공개된 것

- Qwen3-32B · 배치 b8~b256
- SLO = per-user 20/30/40 TPS
- 사용자 수 = 그 SLO 에서 받는 동시 사용자
- 전력 3kW vs 6.6kW · 칩 180W

블로그가 안 밝힌 것

- 입력 / 출력 토큰 길이
- 서빙 엔진 (양측 모두)
- 한 모델당 카드 수 (TP)
- " 사용자 수 " 계산식

우리 재현 방식

- 1 장 vs 1 대 (per-device)
- ISL 1024 / OSL 256 고정
- 양쪽 FP8 · 공통 loadgen
- raw + 전력정규화 둘 다 측정

측정 환경 — 같은 클라이언트, 다른 장비

OpenAI 호환 /v1/completions 만 호출 → 서버 계층만 바꿔 RNGD·GPU 를 같은 코드로 측정

공통 loadgen

closed-loop 배치 스왑
고정 ISL/OSL · 고유 프롬프트
TTFT·per-user· 집계 TPS + 전력 동시측정



RNGD 경로

furiosa-llm serve

qwen3-32b-fp8-tp8 · npu 1 카드 · furiosa-smi 전력

GPU 경로

vllm serve

Qwen/Qwen3-32B-FP8 W8A8 · 1 대 · nvidia-smi 전력

배치 = 동시 사용자

b1·8·16·32·64·256 동시 요청을 항상
in-flight 유지 (closed-loop). 배치 =
그 순간 동시 사용자 수.

고정 ISL/OSL

입력 1024 / 출력 256 토큰 고정
(ignore_eos+min_tokens 로 정확히
256). 양쪽 같은 프롬프트 → 공정.

per-user TPS · SLO

각 사용자가 받는 출력속도 (tok/s).
블로그처럼 20/30/40 TPS 를 SLO
기준선으로 사용.

전력 동시 샘플링

측정 구간 동안 1Hz 로 카드 전력 (W)
수집 → tokens/s/W·users/kW 계산.


처리량 — raw 는 GPU 가 빠르다

단일 PRO 6000 은 동시성이 늘수록 계속 확장 (984 tok/s), RNGD 1 장은 b32 에서 ~377 로 포화

배치별 집계 출력 처리량 (tok/s)

RNGD (1 장 · tp8)

RTX PRO 6000 (1 대)



b1-b16 저부하 격차 작음

단일 · 소수 사용자에서는 차이가 작다 (b1 25.5 vs 37.6). RNGD 1 장도 충분.

b32 RNGD 포화 시작

RNGD 는 b32 에서 377 tok/s 로 천장 . 1 카드 8 PE 의 배치 한계 .


b64-b256 GPU 계속 확장

PRO 6000 은 984 까지 확장 (b256). 피크 처리량 GPU 가 RNGD 의 2.6 배 .

per-user 속도 & SLO 사용자 수

블로그의 20/30/40은 '사용자 1명당 보장 tok/s' 기준선 — RNGD 1장 단일스트림 천장은 25 tok/s

배치별 per-user 출력 TPS (p50) ■ RNGD (1장 · tp8) ■ RTX PRO 6000 (1대)



SLO 20·30·40 TPS/user 기준선 = 각 사용자 최소 보장속도

SLO 당 최대 동시 사용자 (raw, 장비 1개)

SLO	RNGD	PRO6000
20 TPS	7.3 명	44.8 명
30 TPS	0	19.1 명
40 TPS	0	0

천장 단일스트림 25 vs 38


RNGD 1장은 한 명에게도 25 tok/s가 최대 → 30·40 SLO는 1장으로 도달 불가. GPU는 단일스트림이 빨라 (38) 더 높은 SLO·더 많은 사용자.

블로그처럼 하려면 RNGD 멀티카드 필요

블로그는 4x RNGD. 카드를 묶으면 (tp16/32) 단일스트림이 빨라져 30·40 SLO도 도달. 1장 비교의 한계.

전력과 에너지효율 — 여기가 RNGD 의 무대


RNGD 는 1/3 전력으로 동작 → 와트당 처리량 (tokens/s/W) 이 저 ~ 중부하에서 최대 2.03 배



TTFT — 중부하까진 RNGD 가 더 빠르다

b8~b32 에서 RNGD 첫 토큰이 더 빠름 . 단 b64↑ 에서는 RNGD 가 큐 포화로 급증

TTFT p50 (초)



b8~b32 RNGD 첫 토큰 빠름

RNGD 0.76~0.78s vs GPU 1.52~2.53s. 대화형 응답 체감 RNGD 우위 (최대 3.25x).

b64 이상 RNGD 큐 포화

b64 RNGD 8.4s, b256 143s 로 급증 (1 장 배치 한계). GPU 는 b256 도 15.6s.

시사점 적정 부하대가 핵심

RNGD 1 장은 ~b32 이내 운영이 적합 . 그 이상은 카드 추가 또는 GPU.

종합 — raw vs 전력 정규화

raw 1:1에서는 GPU 우위. 블로그의 RNGD 우위는 '전력 정규화' 관점에서 봐야 한다

(A) raw 최대 사용자 / SLO

SLO	RNGD	PRO6000	RNGD/GPU
20 TPS	7.3	44.8	0.16x
30 TPS	0	19.1	—
40 TPS	0	0	—

(B) 에너지효율 tokens/s/W (RNGD/GPU)

배치	1	8	16	32	64	256
RNGD/ GPU	2.03x	1.72x	1.62x	1.33x	1.07x	1.08x

저 ~ 중부하에서 RNGD 가 와트당 1.6~2.0 배 효율. 고부하에선 GPU 처리량이 커져 효율 격차 축소 (~1.1x).

왜 1:1 raw로는 블로그의 1.8~2x 가 안 나오나

① 카드 수

블로그는 4x RNGD. 멀티카드는 단일스트림 · 처리량이 1장보다 크게 빠르다 → 30~40 SLO 도달, 사용자↑.

② 랙 전력 정규화

1.8~2x는 "normalized for rack power". 15kW 랙에 RNGD 서버 5대 vs GPU 2대 → 전력당 사용자에서 벌어짐.

③ per-card 효율은 입증됨

그럼에도 1장 실측에서 RNGD는 전력 1/3 · 와트당 최대 2배 → 블로그의 '효율' 논지 자체는 성립.

결론 — 무엇을 증명했나

블로그의 '효율' 논지는 1 장 실측으로도 성립. '1.8~2x 사용자'는 멀티카드 + 랙 전력에서 재현

RNGD 가 이기는 지점

- 전력 1/3 ($\approx 180\text{W}$ vs $\approx 500\text{W}$)
- 와트당 효율 최대 2.03 배 (저 ~ 중부하)
- b8~b32 TTFT 더 빠름 (최대 3.25 배)
- 저전력 · 고밀도 → 랙당 더 많은 서버

PRO 6000 이 이기는 지점

- raw 처리량 최대 2.6 배 (984 vs 377 tok/s)
- 단일스트림 1.5 배 (38 vs 25 tok/s)
- 높은 SLO(30~40) 사용자 수
- 고부하 (b64+) 안정적 TTFT

한 줄 결론

단일 카드 raw 성능은 RTX PRO 6000 이 빠르다. 하지만 RNGD 는 같은 작업을 1/3 전력으로 처리해 와트당 효율이 최대 2 배 —
블로그가 강조한 '효율' 우위는 1 장 실측으로도 방향이 확인된다. 블로그의 1.8~2x '사용자 수'를 재현하려면 RNGD 를 4 장으로
묶고 랙 전력 기준으로 정규화해야 한다.